Diplomado 2018 Herramientas de Big Data

Practica final del Modulo 1

Autor:

Iván Gaspar Hérnandez

Email:

iangapcreative@gmail.com

Indice

Objetivo Desarrollar un EndPoint que retorne las noticias en un formato JSON a partir de una consulta.	
	3
Configuración del ambiente	3
Configuración basica	3
Instalando dependencias de Python	
Instalando MongoDB	
Configurando la estructura de datos	8
Preparativos para el despliegue	9
Copiado de codigo fuente y dependencias	
Cargar datos en MongoDB	9
Creando index de busqueda por texto	9
Despliegue de la practica de modulo 1	
Despliegue de aplicación	10
Probando la aplicación	10
Publicando resultados	
Entrega final en GitHub	12

Objetivo

Desarrollar un EndPoint que retorne las noticias en un formato JSON a partir de una consulta.

Configuración del ambiente

Configuración basica

Para esta practia de tomo como referencia el **Vagrantfile** (https://drive.google.com/open? id=1m90lSUJp4N6vv8dpGEh2z337j3-iQCbF&authuser=1) más reciente publicado en el Classroom de Google empleado para este diplomado.

Se edito el Vagrantfile original para agregar el forwarded_port para el puerto 5000 y 27017 que seran asignados al servidor web requerido para esta practica y MongoDB respectivamente.

Con el comando **\$ vagrant up** se inicializa la VM y como se puede apresiar en la siguiente imagen los puertos fueron asignados correctamente.

```
iangap@iangap /backup/cic/modulo1 $ vagrant up
Bringing machine 'default' up with 'virtualbox' provider... 
==> default: Checking if box 'nogala/centos' is up to date...
==> default: Clearing any previously set network interfaces...
==> default: Preparing network interfaces based on configuration...
     default: Adapter 1: nat
==> default: Forwarding ports...
     default: 80 (quest) => 8080 (host) (adapter 1)
     default: 5000 (guest) => 5000 (host) (adapter 1)
     default: 27017 (guest) => 27017 (host) (adapter 1)
default: 22 (guest) => 2222 (host) (adapter 1)
==> default: Running 'pre-boot' VM customizations...
==> default: Booting VM...
==> default: Waiting for machine to boot. This may take a few minutes...
     default: SSH address: 127.0.0.1:2222
     default: SSH username: vagrant
     default: SSH auth method: private key
==> default: Machine booted and ready!
==> default: Checking for guest additions in VM...
     default: The guest additions on this VM do not match the installed version of
     default: The guest additions on this VM do not match the instatted version of default: VirtualBox! In most cases this is fine, but in rare cases it can default: prevent things such as shared folders from working properly. If you see default: shared folder errors, please make sure the guest additions within the default: virtual machine match the version of VirtualBox you have installed on
     default: your host and reload your VM.
     default:
     default: Guest Additions Version: 5.2.18
     default: VirtualBox Version: 5.0
==> default: Mounting shared folders...
     default: /vagrant => /backup/cic/modulo1
```

Con el comando **\$ vagrant ssh** se ingresa a la VM via conexión ssh. A continuación se ejecuta el comando **\$ hostnamectl set-hostname igaspar** para personalizar en nombre de dominio asignado a esta VM.

Instalando dependencias de Python

Se requieren un par de librerias no estandar para ejecutar los programas solicitados, para la instalacion se hace uso de la herramienta **pip** que es la herramienta de gestion de librerias de Python.

A continuación se listan las librerias que fueron instaladas.

sudo pip3.6 install pymongo

```
[vagrant@igaspar modulo1]$ sudo pip3.6 install flask
Collecting flask
  Downloading https://files.pythonhosted.org/packages/7f/e7/08578
                                               92kB 1.0MB/s
    100% |
Collecting Jinja2>=2.10 (from flask)
  Downloading https://files.pythonhosted.org/packages/7f/ff/ae64ba
    100% |
                                               | 133kB 2.2MB/s
Collecting Werkzeug>=0.14 (from flask)
  Downloading https://files.pythonhosted.org/packages/20/c4/12e3e5
                                                327kB 1.6MB/s
Collecting itsdangerous>=0.24 (from flask)
  Downloading https://files.pythonhosted.org/packages/dc/b4/a60bcd
                                                51kB 9.6MB/s
    100% |
Collecting click>=5.1 (from flask)
  Downloading https://files.pythonhosted.org/packages/34/c1/8806f9
                                               || 71kB 13.2MB/s
Collecting MarkupSafe>=0.23 (from Jinja2>=2.10->flask)
  Downloading https://files.pythonhosted.org/packages/4d/de/32d74
Installing collected packages: MarkupSafe, Jinja2, Werkzeug, itsda
Running setup.py install for MarkupSafe ... done
Running setup.py install for itsdangerous ... done
Successfully installed Jinja2-2.10 MarkupSafe-1.0 Werkzeug-0.14.1
[vagrant@igaspar modulo1]$
```

Instalando MongoDB

Se agrega un nuevo repositorio yum con las dependencias de MongoDB, con los siguientes pasos:

* Se crea un nuevo archivo de configuración con el siguiente comando:

```
$ sudo vi /etc/yum.repos.d/mongodb-org-4.0.repo
```

* El archivo mongodb-org-4.0.repo debe tener el siguiente contenido:

[mongodb-org-4.0]

name=MongoDB

Repository

baseurl=https://repo.mongodb.org/yum/redhat/\$releasever/mongodb-org/4.0/x86 64/

gpgcheck=1

enabled=1

apgkey=https://www.mongodb.org/static/pgp/server-4.0.asc

* Para instalar mongo se usa el comando:

\$ sudo yum install -y mongodb-org

```
| Transaction Summary | Transaction Summary
```

* Iniciar el demonio mongod con el comando:

\$ sudo systemctl start mongod

* Ingresar con el cliente mongo una sesion con el comando:

\$ mongo

* Crear el usuario que se usara desde la aplicación Python:

db.createUser({user: "root", pwd: "Cic1234*", roles:[{role: "root", db: "admin"}]})

* Se cambia el script de arranque de MongoDB para que solicite autenticación. El scritp se llama /lib/systemd/system/mongod.service, con un editor de texto se abre y se edita para cambiar la linea ExecStart=/usr/bin/mongod \$OPTIONS

por

ExecStart=/usr/bin/mongod --auth \$OPTIONS

```
[Unit]
Description=MongoDB Database Server
After=network.target
Documentation=https://docs.mongodb.org/manual
[Service]
User=mongod
Group=mongod
Environment="OPTIONS=-f /etc/mongod.conf"
EnvironmentFile=-/etc/sysconfig/mongod
ExecStart=/usr/bin/mongod --auth $OPTIONS
ExecStartPre=/usr/bin/mkdir -p /var/run/mongodb
ExecStartPre=/usr/bin/chown mongod:mongod /var/run/mongodb
ExecStartPre=/usr/bin/chmod 0755 /var/run/mongodb
PermissionsStartOnly=true
PIDFile=/var/run/mongodb/mongod.pid
Type=forking
‡ file size
LimitFSIZE=infinity
# cpu time
LimitCPU=infinity
t virtual memory size
LimitAS=infinity
# open files
LimitNOFILE=64000
# processes/threads
LimitNPROC=64000
# locked memory
LimitMEMLOCK=infinity
# total threads (user+kernel)
TasksMax=infinity
TasksAccounting=false
```

* Crear usuario especifico para la base de datos newsdb, para esto se usa el comando: \$db.createUser({ user: 'cic', pwd: 'cic1234*', roles: ["readWrite", "dbAdmin"] });

```
vagrant@igaspar modulo1]$ mongo -u root -p Cic1234*
MongoDB shell version v4.0.2
connecting to: mongodb://127.0.0.1:27017
 MongoDB server version: 4.0.2
Tongobb Server Ver Version: 4.0.2
Server has startup warnings:
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten]
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten]
                                                                           [initandlisten] ** WARNING: /sys/kernel/mm/transparent_hugepage/enabled is 'always
                                                                                                                           We suggest setting it to 'never
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten]
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten] **
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten] **
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten]
                                                                          [initandlisten] ** WARNING: /sys/kernel/mm/transparent_hugepage/defrag is 'always
                                                                                                                           We suggest setting it to 'never
Enable MongoDB's free cloud-based monitoring service, which will then receive and display metrics about your deployment (disk utilization, CPU, operation statistics, etc).
The monitoring data will be available on a MongoDB website with a unique URL accessible to you and anyone you share the URL with. MongoDB may use this information to make product improvements and to suggest MongoDB products and deployment options to you.
To enable free monitoring, run the following command: db.enableFreeMonitoring()
To permanently disable this reminder, run the following command: db.disableFreeMonitoring()
admin 0.000GB
config 0.000GB
local 0.000GB
newsdb 0.000GB
  use newsdb
 witched to db newsdb
 > db.createUser({ user: 'cic', pwd: 'cic1234*', roles: [ "readWrite", "dbAdmin" ] });
Successfully added user: { "user" : "cic", "roles" : [ "readWrite", "dbAdmin" ] }
```

Configurando la estructura de datos

Se requiere crear la base de datos y la colección que requiere la aplicación escrita en Python. Se requiere ejecutar los siguientes pasos:

* Ingresar a MongoDB con el comando

\$ mongo -u root -p

* Crear la base de datos con el comando

\$ use newsdb

* Crear la colección con el comando

\$ db.createCollection("news")

* Verificar que la colección existe con el comando

\$ show collections

```
[vagrant@igaspar ~]$ mongo -u root -p
MongoDB shell version v4.0.2
Connecting to: mongodb://127.0.0.1:27017

MongoDB server version: 4.0.2

Server has startup warnings:
2018-09-13723:19:24.921-0500 I CONTROL [initandlisten]
2018-09-13723:19:24.921-0500 I CONTROL [initandlisten]
                                                                            [initandlisten] ** WARNING: /sys/kernel/mm/transparent_hugepage/enabled is 'always'
2018-09-13T23:19:24.921-0500 I CONTROL
                                                                             [initandlisten] **
                                                                                                                           We suggest setting it to 'never
2018-09-13723:19:24.921-0500 I CONTROL [initandlisten] ** WARNING: /sys/kernel/mm/transparent_hugepage/defrag is 'always'.
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten] ** We suggest setting it to 'never'
2018-09-13T23:19:24.921-0500 I CONTROL [initandlisten]
---
Enable MongoDB's free cloud-based monitoring service, which will then receive and display
metrics about your deployment (disk utilization, CPU, operation statistics, etc).
The monitoring data will be available on a MongoDB website with a unique URL accessible to you
and anyone you share the URL with. MongoDB may use this information to make product
improvements and to suggest MongoDB products and deployment options to you.
To enable free monitoring, run the following command: db.enableFreeMonitoring()
To permanently disable this reminder, run the following command: db.disableFreeMonitoring()
  use newsdb
switched to db newsdb
> db.createCollection(news)
2018-09-13T23:26:36.896-0500 E QUERY
@(shell):1:1
                                                                            [js] ReferenceError: news is not defined :
   db.createCollection("news")
2018-09-13T23:26:50.363-0500 E QUERY [js] Error: don't know how to show [colection] : shellHelper.show@src/mongo/shell/utils.js:1055:11 shellHelper@src/mongo/shell/utils.js:766:15
@(shellhelp2):1:1
> Show Colections
2018-09-13T23:26:53.562-0500 E QUERY [js] Error: don't know how to show [colections] :
shellHelper.show@src/mongo/shell/utils.js:1055:11
shellHelper@src/mongo/shell/utils.js:766:15
@(shellhelp2):1:1
> show collections
```

Preparativos para el despliegue

Copiado de codigo fuente y dependencias

Los archivos TodasLasNoticias.csv, loadData.py y modulo1.py son copiados al directorio /backup/cic/modulo1 que es donde se encuentra el archivo Vagrantfile para poder de esta forma tener acceso a estos archivos desde la VM.

Para tener mayor orden se creara un directorio de trabajo con el comando **\$ mkdir -p** /home/vagrant/modulo1. Mover los archivos TodasLasNoticias.csv, loadData.py y modulo1.py con el comando my al nuevo directorio de trabajo.

Cargar datos en MongoDB

Ir al directorio de trabajo con el comando **\$cd /home/vagrant/modulo1**/, ejecutar el programa encargado de leer el archivo CSV con las noticias y gurdar estos registros en MongoDB, para hacer esto solo hace falta ejecutar el siguiente comando:

\$python3.6 loadData.py

```
[vagrant@igaspar modulo1]$ python3.6 loadData.py
OK_data:233896
bad_data:10540
[vagrant@igaspar modulo1]$|
```

El valor **OK_data** se refiere al número total de registros cargados en MongoDB y la leyenda **bad_data** se refiere a los registros en el CSV que no tenian la estructura esperada para poder ser almacenados en MongoDB.

Creando index de busqueda por texto

MongoDB cuenta con la caracteristica de poder ejecutar busquedas en base a texto, para esto es necesario crear un indice sobre los campos de la colección sobre los cuales nos interesa realizar las busquedas. La creación del indice se realiza con el comando:

```
$ db.news.createIndex( { title: "text", new: "text" } )
```

Despliegue de la practica de modulo 1

Despliegue de aplicación

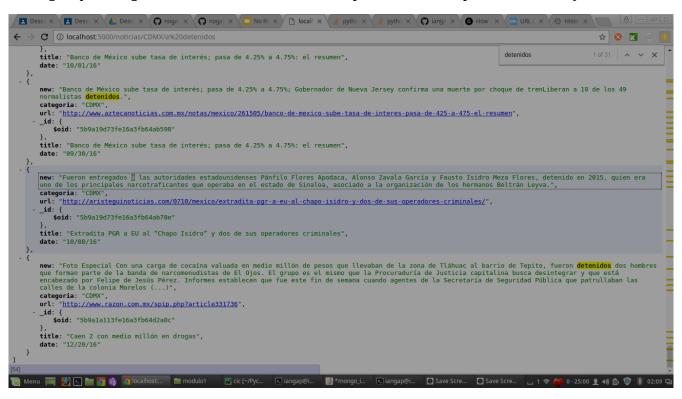
En el directorio de trabajo /home/vagrant/modulo1/ se ejecuta el comando \$ python3.6 modulo1.py lo cual desplegara en el puerto 5000 el endpoint solicitado

Probando la aplicación

Resultado de la busqueda con categoria economia y palabra clave cambio

Resultado de la busqueda con categoria politica y palabra clave gato

Resultado de la busqueda con categoria **CDMX** y las palabra clave **a** y **detenidos**, se puede apreciar en la imagen que el registro resaltado en azul no tiene la palabra detenido pero si **detenido** y la letra a



Publicando resultados

Entrega final en GitHub

Tanto el codigo fuente de la aplicación Python asi como esta practica se pueden encontrar en GitHub en https://github.com/iangapcreative/modulo1

o clonando el proyecto con el comando

\$ git clone https://github.com/iangapcreative/modulo1.git